



FACULTAD DE INGENIERÍA

Sistemas multiagente

Simultaneous Game.

FECHA DE ENTREGA: 27/05/2026

Profesor:

Marcos Adrian Begerez Oyhenard

Martín Iturbide Noria

Alumnos:

Natalia Campiglia - 349251

Marcos Mussio - 362839

Índice

1. Introducción	4
2. Marco Teórico	6
2.1. Aprendizaje por Refuerzo Multiagente	6
2.2. Juegos Simultáneos	6
2.2.1. Equilibrio de Nash	6
2.3. Fictitious Play	7
2.4. Regret Matching	7
2.5. Independent Q-Learning	8
2.6. Joint-Action Learning with Agent Modeling	8
3. Ambientes	10
3.1. Matching Pennies	10
3.2. Rock-Paper-Scissors	10
3.3. Blotto	11
3.4. Three-Player Game	12
3.5. Foraging	15
3.6. Cournot	16
3.7. Chicken	17
3.8. Battle of sexes	17
4. Experimentos	19
4.1. Matching-Pennies	19
4.2. Blotto	33
4.3. Battle-Of-Sexes	41
4.4. Chicken	54
4.5. Rock-Paper-Scissors	63

4.6. Three-Player Game	72
4.7. Foraging	85
4.8. Cournot	96
5. Conclusion	109

1. Introducción

Los sistemas multiagente (Multi-Agent Systems, MAS) constituyen un área de estudio de la inteligencia artificial enfocada en escenarios donde múltiples agentes autónomos interactúan dentro de un ambiente compartido para alcanzar determinados objetivos. Estos agentes pueden colaborar, competir o mantener objetivos parcialmente alineados, generando dinámicas complejas de coordinación y toma de decisiones. En este contexto, el aprendizaje por refuerzo multiagente (Multi-Agent Reinforcement Learning, MARL) surge como una extensión del aprendizaje por refuerzo tradicional, permitiendo que varios agentes aprendan simultáneamente mediante interacción repetida con el ambiente y entre ellos.

En MARL, cada agente observa el estado del entorno, ejecuta acciones y recibe recompensas que guían el proceso de aprendizaje. Sin embargo, a diferencia del caso single-agent, la presencia de múltiples agentes introduce desafíos adicionales, tales como la no estacionariedad del entorno, la necesidad de coordinación y la existencia de equilibrios estratégicos. Debido a esto, muchos algoritmos de aprendizaje multiagente combinan conceptos provenientes tanto del aprendizaje por refuerzo como de la teoría de juegos.

El objetivo de este trabajo es implementar y analizar distintos algoritmos clásicos de aprendizaje multiagente, evaluando su comportamiento en diversos ambientes competitivos y cooperativos. Para ello, se desarrollaron implementaciones de Fictitious Play (FP), Regret Matching (RM), Independent Q-Learning (IQL) y Joint-Action Learning with Agent Modeling (JAL-AM).

El código utilizado para los experimentos se encuentra disponible públicamente en el repositorio `mmussio85/simultaneous-games`.

De acuerdo con la consigna del obligatorio, los algoritmos fueron validados utilizando diferentes ambientes de prueba, incluyendo Matching Pennies, Rock-Paper-Scissors (RPS), Blotto y Foraging. Asimismo, se realizaron múltiples experimentos enfrentando distintos agentes entre sí, por ejemplo FP vs FP, FP vs RM e IQL vs IQL, con el objetivo de analizar propiedades como conver-

gencia, estabilidad, capacidad de coordinación y adaptación estratégica.

Los ambientes seleccionados permiten estudiar diferentes tipos de interacción multiagente. Juegos como Matching Pennies y Rock-Paper-Scissors representan escenarios competitivos de suma cero donde el equilibrio de Nash juega un rol central, mientras que ambientes como Foraging permiten analizar problemas de cooperación y coordinación entre múltiples agentes.

El informe se encuentra organizado de la siguiente manera. En primer lugar, se presenta el marco teórico necesario sobre sistemas multiagente, aprendizaje por refuerzo y teoría de juegos. Luego, se describen los algoritmos implementados y los ambientes utilizados. Posteriormente, se detallan los aspectos de implementación y el diseño experimental empleado para evaluar los algoritmos. Finalmente, se presentan y analizan los resultados obtenidos, discutiendo las fortalezas y limitaciones observadas en cada enfoque.

2. Marco Teórico

2.1. Aprendizaje por Refuerzo Multiagente

El aprendizaje por refuerzo multiagente (Multi-Agent Reinforcement Learning, MARL) estudia escenarios donde múltiples agentes aprenden simultáneamente mediante interacción con un ambiente compartido. Cada agente observa el estado del entorno, ejecuta acciones y recibe recompensas que guían su aprendizaje.

A diferencia del aprendizaje por refuerzo tradicional, en MARL el entorno se vuelve no estacionario, ya que las políticas de los demás agentes cambian durante el entrenamiento.

2.2. Juegos Simultáneos

En este trabajo se consideran principalmente juegos simultáneos, donde todos los agentes seleccionan sus acciones al mismo tiempo. Un juego puede representarse mediante:

$$G = (I, A, R)$$

Donde I es el conjunto de jugadores, A representa las acciones disponibles y R representa las recompensas asociadas a las acciones conjuntas.

2.2.1. Equilibrio de Nash

Un equilibrio de Nash corresponde a una estrategia conjunta donde ningún jugador puede mejorar su recompensa modificando unilateralmente su estrategia.

$$\forall i \in I : \pi_i^* \in BR_i(\pi_{-i}^*)$$

En juegos como Matching Pennies y Rock-Paper-Scissors, el equilibrio se encuentra en estra-

tegias mixtas.

2.3. Fictitious Play

Fictitious Play (FP) es un algoritmo donde cada agente estima las estrategias de los demás jugadores a partir de las acciones observadas previamente y responde utilizando una mejor respuesta. El agente mantiene una creencia sobre la política promedio de sus oponentes, calculada a partir de frecuencias históricas, y elige la acción que maximiza su recompensa esperada frente a esa creencia. Por eso puede jugar acciones puras en cada iteración, aunque su comportamiento promedio puede aproximarse a una estrategia mixta.

En juegos competitivos de suma cero, como Matching Pennies o Rock-Paper-Scissors, se espera que la política promedio de FP se acerque al equilibrio mixto. En juegos con equilibrios puros claros o de coordinación, suele concentrar progresivamente su política en acciones compatibles con el comportamiento observado de los demás agentes.

2.4. Regret Matching

Regret Matching (RM) es un algoritmo basado en el concepto de arrepentimiento (regret). El agente compara la recompensa obtenida con la que habría recibido si hubiera elegido otras acciones en el pasado, aumentando la probabilidad de aquellas acciones con arrepentimiento positivo. De esta forma, la política resultante es estocástica y depende de los regrets acumulados durante el entrenamiento.

En juegos de suma cero, RM suele favorecer la aproximación a equilibrios en términos de comportamiento promedio, especialmente cuando ambos agentes reducen su arrepentimiento con el tiempo. En juegos de coordinación o con equilibrios puros, puede concentrar rápidamente la probabilidad en acciones ventajosas, aunque puede oscilar si varias acciones tienen incentivos parecidos.

2.5. Independent Q-Learning

Independent Q-Learning (IQL) aplica Q-Learning de manera independiente para cada agente. Cada agente aprende una función de valor propia, asociando estados y acciones individuales con recompensas esperadas, sin representar explícitamente las acciones elegidas por los demás. Desde su punto de vista, los otros agentes forman parte del entorno.

La actualización de la función Q se realiza mediante:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

La política de IQL se deriva de los valores Q aprendidos, favoreciendo acciones con mayor valor estimado y manteniendo exploración durante el entrenamiento. Su ventaja principal es la simplicidad, pero en juegos competitivos puede ser inestable porque cada agente aprende mientras los demás también cambian su política. En ambientes de coordinación puede aprender políticas útiles, aunque no garantiza por sí solo una convergencia estable ni un reparto equilibrado de recompensas.

2.6. Joint-Action Learning with Agent Modeling

Joint-Action Learning with Agent Modeling (JAL-AM) extiende Q-Learning incorporando modelos sobre las acciones de los demás agentes, aprendiendo valores asociados a acciones conjuntas.

$$Q(s, a_i, a_{-i})$$

A diferencia de IQL, JAL-AM evalúa las acciones propias considerando también posibles acciones de los demás agentes. Para eso mantiene un modelo del comportamiento de los oponentes, generalmente basado en frecuencias observadas, y lo utiliza para calcular el valor esperado de sus decisiones.

En juegos competitivos, JAL-AM puede reducir parte de la no estacionariedad al hacer explícito el efecto de las acciones del oponente, aunque no elimina completamente las oscilaciones cuando todos los agentes aprenden simultáneamente. En ambientes cooperativos o de coordinación, el modelado de acciones conjuntas puede ayudar a identificar comportamientos compatibles, pero su desempeño depende de la calidad del modelo aprendido y del tamaño del espacio de acciones conjuntas.

3. Ambientes

Con el objetivo de evaluar el comportamiento de los algoritmos implementados, se realizaron experimentos sobre distintos ambientes competitivos y cooperativos. Cada ambiente presenta características diferentes, permitiendo analizar propiedades como convergencia, estabilidad, adaptación estratégica y coordinación entre agentes.

3.1. Matching Pennies

Matching Pennies es un juego competitivo de suma cero para dos jugadores. Cada jugador debe elegir simultáneamente entre dos acciones: *Heads* o *Tails*.

Si ambos jugadores seleccionan la misma acción, el jugador 1 obtiene una recompensa positiva y el jugador 2 una recompensa negativa. En caso contrario, ocurre lo inverso.

La matriz de pagos utilizada es la siguiente:

	H	T
H	$(1, -1)$	$(-1, 1)$
T	$(-1, 1)$	$(1, -1)$

Este ambiente resulta útil para analizar convergencia hacia estrategias mixtas y equilibrio de Nash.

3.2. Rock-Paper-Scissors

Rock-Paper-Scissors (RPS) es un juego simultáneo de suma cero con dos agentes y tres acciones posibles: Rock (R), Paper (P) y Scissors (S).

Las reglas son las siguientes:

- Rock vence a Scissors.
- Scissors vence a Paper.
- Paper vence a Rock.

La matriz de recompensas utilizada es:

	R	P	S
R	$(0, 0)$	$(-1, 1)$	$(1, -1)$
P	$(1, -1)$	$(0, 0)$	$(-1, 1)$
S	$(-1, 1)$	$(1, -1)$	$(0, 0)$

El único equilibrio de Nash del juego corresponde a la estrategia mixta uniforme $\pi^* = (1/3, 1/3, 1/3)$ para ambos jugadores. Por este motivo, este ambiente resulta útil para evaluar si los algoritmos logran aproximarse a una política balanceada y si las recompensas se mantienen alrededor de cero en el largo plazo.

3.3. Blotto

Blotto es un juego estratégico donde los agentes deben distribuir recursos limitados entre múltiples campos de batalla. Cada campo es ganado por el jugador que asigna mayor cantidad de recursos.

El objetivo consiste en maximizar la cantidad de campos ganados o la recompensa total obtenida.

Este ambiente introduce un espacio de acciones más complejo que Matching Pennies y RPS, permitiendo analizar la capacidad de exploración y adaptación estratégica de los algoritmos.

3.4. Three-Player Game

Three-Player Game es un juego simultáneo de tres agentes donde cada configuración define una matriz de recompensas distinta y, en algunos casos, también cambia la cantidad de acciones disponibles para **agent_2**. A diferencia de Matching Pennies y RPS, no se trata de un juego de suma cero con equilibrio mixto, sino de un conjunto de juegos con estructura estratégica más variada. Esto permite evaluar de forma directa si los algoritmos logran concentrar su política en acciones de equilibrio cuando existe una solución pura clara, y qué ocurre cuando la matriz de pagos introduce incentivos de desviación más complejos.

Las acciones disponibles en cada configuración, según **REWARD_MATRICES**, son:

Configuración	agent_0	agent_1	agent_2	Perfiles posibles
1	T, B	L, R	W, E	$2 \times 2 \times 2 = 8$
2	T, B	L, R	W, E	$2 \times 2 \times 2 = 8$
3	T, B	L, R	W, E, N	$2 \times 2 \times 3 = 12$
4	T, B	L, R	W, E, N	$2 \times 2 \times 3 = 12$

Tabla 1: Acciones disponibles por agente en las configuraciones de Three-Player Game.

En esta notación, **agent_0** elige entre *Top* (T) y *Bottom* (B), **agent_1** elige entre *Left* (L) y *Right* (R), y **agent_2** elige entre *West* (W), *East* (E) y, en las configuraciones 3 y 4, *North* (N).

Config.	Equilibrios de Nash	Pagos	Observación principal
1	(B, R, W)	$(3, 4, 2)$	Equilibrio puro claro; se espera concentración en una acción por agente.
2	(B, L, W) y (B, L, E)	$(1, 1, 1)$	agent_2 puede mezclar entre W y E sin salir del equilibrio.
3	(T, R, W) , (T, R, N) , (B, L, W) y (B, L, N)	Bajos o desbalanceados	Equilibrios puros débiles; no se espera convergencia limpia.
4	(B, L, W) y (B, L, N)	$(1, 1, 1)$	agent_2 puede mezclar entre W y N dentro del equilibrio.

Tabla 2: Resumen estratégico de las configuraciones de Three-Player Game.

En algunas configuraciones, un agente puede tener más de una acción equivalente dentro del equilibrio. En ese caso, no necesariamente se espera que una acción tenga probabilidad 1 y las demás probabilidad 0: el agente puede mantener probabilidad positiva en varias acciones sin dejar de estar en equilibrio de Nash. Además, como las gráficas resumen entrenamientos promedio, también puede ocurrir que distintas ejecuciones terminen cerca de equilibrios distintos, haciendo que el promedio no llegue exactamente a 1 en una sola acción.

Configuración 1

La matriz de pagos utilizada corresponde a la configuración 1 del ambiente. Las filas representan las acciones de **agent_0**, las columnas las acciones de **agent_1**, y cada tabla fija la acción de **agent_2**.

		agent_2 = W		agent_2 = E	
		L	R	L	R
T		(0, 0, 0)	(2, 8, 6)	T	(0, 0, 0) (1, 2, 5)
B		(5, 3, 2)	(3, 4, 2)	B	(1, 6, 1) (0, 0, 1)

El equilibrio de Nash puro se encuentra en el perfil (B, R, W) , con pagos $(3, 4, 2)$. Ningún agente puede mejorar unilateralmente desviándose de esa acción mientras los demás mantienen su estrategia. Por este motivo, la evaluación del ambiente se centra en la probabilidad asignada por cada agente a su acción de equilibrio y en la distancia de la política aprendida respecto al equilibrio.

Configuración 2

En la configuración 2, el juego mantiene dos acciones por agente. Los perfiles (B, L, W) y (B, L, E) son equilibrios de Nash puros con pagos $(1, 1, 1)$. Además, como para **agent_2** las acciones W y E dan el mismo pago cuando los otros agentes juegan (B, L) , cualquier mezcla entre W y E también es compatible con un equilibrio: **agent_0** juega B , **agent_1** juega L y **agent_2** puede repartir probabilidad entre W y E . También existen perfiles con recompensa conjunta mayor, como (T, R, W) y (T, R, E) , que entregan pagos $(3, 3, 3)$, pero no son equilibrios de Nash porque algún agente puede mejorar desviándose unilateralmente.

Configuración 3

La configuración 3 aumenta la complejidad porque **agent_2** tiene tres acciones: W , E y N . En esta matriz aparecen perfiles con pagos altos, por ejemplo (T, L, E) y (B, R, E) con pagos $(2, 2, 2)$, pero no son equilibrios puros porque **agent_2** puede desviarse para obtener una recompensa mayor. La matriz también contiene varios equilibrios puros débiles, como (T, R, W) , (T, R, N) , (B, L, W) y (B, L, N) , pero estos perfiles tienen pagos bajos o desbalanceados y muchas indiferencias. Por este motivo, no se espera una convergencia tan limpia como en las configuraciones con equilibrio puro claro y atractivo.

Configuración 4

La configuración 4 también utiliza tres acciones para **agent_2**, pero modifica varios pagos respecto a la configuración 3 e introduce mayor asimetría entre los agentes. Sus equilibrios de Nash puros son (B, L, W) y (B, L, N) , ambos con pagos $(1, 1, 1)$. Al igual que en la configuración 2, hay una parte común en los equilibrios: **agent_0** debe jugar B y **agent_1** debe jugar L . Para **agent_2**, las acciones W y N son equivalentes dentro del equilibrio, mientras que E no forma parte de esos perfiles de equilibrio.

3.5. Foraging

Foraging es un ambiente multiagente secuencial en el que varios agentes se desplazan dentro de una grilla para recolectar comida. En cada paso, los agentes observan el estado del entorno, eligen una acción de movimiento o la acción **LOAD**, y reciben recompensa cuando el recurso es recolectado. A diferencia de juegos matriciales como Matching Pennies o RPS, aquí las decisiones no dependen solamente de una acción simultánea aislada, sino también de la posición de los agentes, la ubicación de la comida y la historia del episodio.

El ambiente permite estudiar coordinación, competencia por recursos escasos y cooperación. En las configuraciones no cooperativas, puede ocurrir que un agente llegue antes a la comida y concentre una mayor parte de la recompensa. En las configuraciones cooperativas, en cambio, los agentes deben coordinar sus posiciones y acciones para recolectar el recurso, por lo que el desempeño individual depende más fuertemente del comportamiento conjunto.

Configuración	Mapa	Agentes	Comida	Característica principal
Foraging-5x5-2p-1f-v3	5×5	2	1	Escenario pequeño, exploración simple.
Foraging-8x8-2p-1f-v3	8×8	2	1	Mayor espacio de estados y trayectorias más largas.
Foraging-8x8-3p-1f-v3	8×8	3	1	Más agentes compiten o se coordinan alrededor del mismo recurso.
Foraging-8x8-3p-1f-coop-v3	8×8	3	1	Modo cooperativo, requiere coordinación para recolectar.

Tabla 3: Configuraciones evaluadas del ambiente Foraging.

En los experimentos de Foraging se evaluaron IQL y JAL-AM, ya que ambos algoritmos permiten aprender políticas dependientes del estado. A diferencia de los juegos matriciales, este ambiente no se evalúa mediante una distancia directa a un equilibrio de Nash conocido, sino usando métricas de aprendizaje por refuerzo: recompensa promedio por episodio, cantidad promedio de pasos hasta recolectar la comida y distribución de recompensas entre agentes.

Además, como es un juego multiagente, también interesa analizar la estabilidad de las políticas aprendidas en relación con el equilibrio de Nash. En este caso no hay un equilibrio simple y conocido como en RPS, porque el juego tiene estados y se desarrolla a lo largo de varios pasos. Por eso, se evalúa de forma empírica si los agentes logran coordinarse y si alguno podría mejorar claramente cambiando su política mientras los demás mantienen la suya.

3.6. Cournot

Cournot es un juego económico simultáneo donde dos o más empresas compiten eligiendo cuánto producir de un mismo bien. Todas las empresas toman su decisión al mismo tiempo y, una vez definidas las cantidades, el precio de mercado se determina a partir de la producción total.

La idea central es que, si la producción total aumenta, el precio de mercado disminuye. Por lo tanto, cada agente debe decidir cuánto producir considerando tanto su propio beneficio como el efecto que sus acciones tienen sobre el precio que reciben todos los participantes. Esto genera una tensión estratégica: producir más puede aumentar las ventas individuales, pero también puede reducir el precio de mercado.

En el caso clásico con dos empresas, demanda inversa lineal $P(Q) = a - bQ$ y costo marginal constante c , donde $Q = q_1 + q_2$, la ganancia de cada empresa puede escribirse como:

$$\pi_i(q_i, q_j) = q_i(a - b(q_i + q_j) - c).$$

El equilibrio de Nash se alcanza cuando ninguna empresa puede mejorar su ganancia cam-

biando unilateralmente su cantidad producida, manteniendo fija la producción de la otra. En el caso simétrico de dos empresas, el equilibrio está dado por:

$$q_1^* = q_2^* = \frac{a - c}{3b}.$$

Esto significa que ambas empresas producen la misma cantidad y que ninguna tiene incentivos a desviarse si la otra mantiene su producción fija. En los experimentos, este equilibrio sirve como referencia para evaluar si los algoritmos aprenden cantidades cercanas a la mejor respuesta mutua y si sus políticas convergen hacia un comportamiento estable.

3.7. Chicken

El juego de *Chicken* es un juego clásico de conflicto donde dos agentes tienen incentivos a ser agresivos, pero si ambos son agresivos al mismo tiempo, el resultado es muy malo para los dos.

La idea típica es:

Dos autos van uno hacia el otro.

Cada conductor puede mantenerse firme o desviarse.

Si uno se desvía y el otro no, el que no se desvía “gana”.

Si ambos se desvían, nadie gana del todo, pero evitan el choque.

Si ninguno se desvía, chocan, que es el peor resultado para ambos.

3.8. Battle of sexes

Es un juego en donde los jugadores deben elegir entre ir al **Cine** o a un **Partido** de fútbol. Prefieren ir juntos, pero `agent_0` prefiere el Cine y `agent_1` el Partido.

A diferencia de **Matching Pennies** y **Blotto**, este juego **NO** es de suma cero: ambos jugadores pueden obtener utilidad positiva simultáneamente.

Matrices de utilidades (u_0, u_1) , donde las filas corresponden a **agent_0** y las columnas a **agent_1**:

	Cine	Partido
Cine	(2, 1)	(0, 0)
Partido	(0, 0)	(1, 2)

agent_0 obtiene más utilidad coordinando en Cine; **agent_1**, coincidiendo en Partido. La descoordinación da 0 a ambos.

4. Experimentos

Para evaluar el desempeño de los algoritmos implementados, se realizaron experimentos sobre los ambientes descritos anteriormente. La cantidad de episodios, repeticiones y semillas aleatorias se ajustó según las características de cada ambiente y el objetivo de cada análisis. En algunos casos se priorizó estudiar la trayectoria de aprendizaje de una ejecución representativa, mientras que en otros se utilizaron múltiples semillas para obtener resultados promedio y reducir el efecto de la aleatoriedad. Cuando corresponde, las curvas se reportan como promedios sobre distintas ejecuciones y se acompañan con medidas de variabilidad.

Vale aclarar que para el caso de gráficos de convergencia e histogramas de acciones, la semilla es fija para cada episodio, mientras que para el resto de los gráficos se optó por promediar sobre distintas semillas para obtener una visión más general del comportamiento de los algoritmos.

4.1. Matching-Pennies

En Matching Pennies buscamos estudiar convergencias a equilibrios, histogramas y comparativas en enfrentamiento de agentes.


FP vs FP

Figura 1: Convergencia FP vs FP en MP.




Figura 2: Histogramas FP vs FP en MP.




Figura 3: Reward y Comparación política promedio para FP vs FP.

En el experimento de FP vs FP, ambos agentes convergen hacia el equilibrio de Nash esperado, que corresponde a una estrategia mixta uniforme. Las recompensas oscilan alrededor de cero, lo cual es consistente con un juego de suma cero. Los histogramas muestran que las acciones se distribuyen de manera uniforme a lo largo del entrenamiento, reflejando la naturaleza mixta del equilibrio.

FP vs Random




Figura 4: Convergencia FP vs Random en MP.




Figura 5: Histogramas FP vs Random en MP.

Cuando FP se enfrenta a un agente aleatorio, el algoritmo logra explotar correctamente al oponente. Las recompensas se vuelven positivas para el agente FP, y los histogramas muestran una distribución de acciones que favorece la mejor respuesta frente a un oponente impredecible. Esto

demuestra la capacidad de FP para adaptarse a diferentes tipos de oponentes, aunque en este caso el agente aleatorio no representa un desafío estratégico significativo.

FP vs RM




Figura 6: Convergencia FP vs RM en MP.




Figura 7: Reward y Comparación política promedio para FP vs RM.

En el enfrentamiento entre FP y RM, ambos algoritmos logran aproximar el equilibrio de Nash, aunque RM muestra una convergencia más rápida y estable. Las recompensas oscilan alrededor de cero, y los histogramas indican que ambos agentes distribuyen sus acciones de manera uniforme,

reflejando la naturaleza mixta del equilibrio. Sin embargo, RM parece adaptarse más rápidamente a las estrategias de FP, lo que se traduce en una convergencia más rápida hacia el equilibrio.

IQL vs IQL




Figura 8: Convergencia IQL vs IQL en MP.




Figura 9: Histogramas IQL vs IQL en MP.




Figura 10: Reward y Comparación política promedio para IQL vs IQL.

En el experimento de IQL vs IQL, ambos agentes presentan un comportamiento inestable. Las recompensas oscilan fuertemente durante todo el entrenamiento, y los histogramas muestran una distribución de acciones que varía considerablemente entre episodios.

Esto refleja el problema de no estacionariedad en el aprendizaje por refuerzo multiagente, donde cada agente asume que el entorno es estacionario mientras el oponente también está aprendiendo y modificando su estrategia.

Como resultado, la política de cada agente no converge hacia un equilibrio estable, sino que continúa fluctuando a lo largo del tiempo.

IQL vs JAL-AM




Figura 11: Convergencia IQL vs JAL-AM en MP.




Figura 12: Histogramas IQL vs JAL-AM en MP.

En el enfrentamiento entre IQL y JAL-AM, se observa que JAL-AM logra adaptarse mejor a las estrategias de IQL, aunque ambos agentes siguen mostrando un comportamiento inestable.

Las recompensas oscilan, pero JAL-AM tiende a obtener mejores resultados que IQL, lo que

sugiere que el modelado explícito del oponente en JAL-AM ayuda a reducir parcialmente los efectos de la no estacionariedad.

IQL vs Random




Figura 13: Convergencia IQL vs Random en MP.




Figura 14: Histogramas IQL vs Random en MP.

Cuando IQL se enfrenta a un agente aleatorio, el algoritmo logra adaptarse parcialmente, obteniendo recompensas positivas en promedio.

Sin embargo, la inestabilidad del aprendizaje por refuerzo multiagente sigue presente, y los histogramas muestran una distribución de acciones que varía considerablemente entre episodios.

Esto sugiere que aunque IQL puede explotar a un oponente aleatorio, la falta de modelado explícito del oponente y la asunción de estacionariedad limitan su capacidad para mantener una estrategia estable a lo largo del tiempo.

JAL-AM vs JAL-AM




Figura 15: Convergencia JALAM vs JALAM en MP.




Figura 16: Histogramas JALAM vs JALAM en MP.




Figura 17: Reward y Comparación política promedio para JALAM vs JALAM.

En el experimento de JAL-AM vs JAL-AM, ambos agentes logran adaptarse mutuamente, aunque todavía presentan cierta inestabilidad. Las recompensas oscilan, pero tienden a mantenerse alrededor de cero, lo que es consistente con un juego de suma cero.

Los histogramas muestran una distribución de acciones que varía, aunque con una tendencia a acercarse a la estrategia mixta del equilibrio de Nash.

RM vs Random




Figura 18: Convergencia RM vs Random en MP.




Figura 19: Histogramas RM vs Random en MP.

Cuando RM se enfrenta a un agente aleatorio, el algoritmo logra explotar al oponente de manera efectiva. Las recompensas se vuelven positivas para el agente RM, y los histogramas muestran una distribución de acciones que favorece la mejor respuesta frente a un oponente impredecible.

Esto demuestra la capacidad de RM para adaptarse a diferentes tipos de oponentes, aunque en este caso el agente aleatorio no representa un desafío estratégico significativo.

RM vs RM




Figura 20: Convergencia RM vs RM en MP.




Figura 21: Histogramas RM vs RM en MP.




Figura 22: Reward y Comparación política promedio para RM vs RM.

En el enfrentamiento entre RM y RM, ambos algoritmos logran aproximar el equilibrio de Nash de manera rápida y estable.

Las recompensas oscilan alrededor de cero, y los histogramas indican que ambos agentes distribuyen sus acciones de manera uniforme, reflejando la naturaleza mixta del equilibrio. RM muestra una convergencia más rápida y estable que FP, lo que se traduce en una aproximación más eficiente hacia el equilibrio de Nash.

Todos los agentes logran aproximar el equilibrio de Nash, aunque con diferentes velocidades y niveles de estabilidad. RM es el algoritmo que muestra la convergencia más rápida y estable, seguido por FP.

IQL presenta un comportamiento inestable debido a la no estacionariedad del entorno, mientras que JAL-AM logra mejorar respecto a IQL al incorporar modelado del oponente, aunque todavía presenta cierta inestabilidad.

Conclusiones

En el ambiente de Matching Pennies, los algoritmos FP y RM demostraron una capacidad sólida para converger hacia el equilibrio de Nash, con RM mostrando una convergencia más rápida

y estable.

Por otro lado, IQL presentó un comportamiento inestable debido a la no estacionariedad del entorno, aunque logró adaptarse parcialmente a oponentes aleatorios. JAL-AM mostró una mejora respecto a IQL al incorporar modelado del oponente, aunque todavía presentó cierta inestabilidad.

En general, los resultados reflejan las fortalezas y limitaciones de cada algoritmo en un entorno competitivo de suma cero, destacando la importancia de considerar la naturaleza del juego y el tipo de oponentes al seleccionar un enfoque de aprendizaje multiagente.

4.2. Blotto

Se realizaron experimentos en el ambiente de Blotto enfrentando a los algoritmos implementados entre sí y contra un agente aleatorio. El objetivo fue analizar la capacidad de adaptación estratégica y convergencia hacia equilibrios en un entorno con un espacio de acciones más complejo que Matching Pennies.

FP vs FP




Figura 23: Convergencia FP vs FP en Blotto.




Figura 24: Reward y Comparación política promedio para FP vs FP.

Evaluando ambos gráficos, el agente FP descubre $(2, 2, 2)$ como una estrategia dominante, lo que sugiere que ambos agentes convergen hacia un equilibrio de Nash donde asignan recursos de manera uniforme entre los campos de batalla. La convergencia se da de manera relativamente rápida, y las recompensas oscilan alrededor de cero, lo que es consistente con un juego de suma cero.

FP vs Random




Figura 25: Convergencia FP vs Random en Blotto.

Debido a que el agente FP descubre la estrategia dominante $(2, 2, 2)$, logra explotar al agente aleatorio, obteniendo recompensas cero en promedio.

La política del agente FP se adapta para maximizar su recompensa frente a un oponente impredecible, mientras que el agente aleatorio no representa un desafío estratégico significativo.

FP vs RM




Figura 26: Convergencia FP vs RM en Blotto.




Figura 27: Reward y Comparación política promedio para FP vs RM.

En el enfrentamiento entre FP y RM en Blotto, FP converge hacia la estrategia dominante $(2, 2, 2)$, mientras que RM muestra una convergencia más lenta y menos estable.

Las recompensas tienden a cero, y la convergencia de la política promedio converge rápidamente hacia la política dominante.

IQL vs IQL

Convergencia: IQL vs IQL — Blotto (S=6, N=3)




Figura 28: Convergencia IQL vs IQL en Blotto.




Figura 29: Reward y Comparación política promedio para IQL vs IQL.

En el experimento de IQL vs IQL en Blotto, ambos agentes presentan un comportamiento inestable, con recompensas que oscilan en cero durante todo el entrenamiento.

IQL vs JAL-AM




Figura 30: Convergencia IQL vs JAL-AM en Blotto.

En el enfrentamiento entre IQL y JAL-AM en Blotto, se observa que JAL-AM logra adaptarse mejor a las estrategias de IQL, aunque ambos agentes siguen mostrando un comportamiento inestable. Las recompensas oscilan, pero JAL-AM tiende a obtener mejores resultados que IQL.

IQL vs Random




Figura 31: Convergencia IQL vs Random en Blotto.

Se observa un aprendizaje parcial por parte de IQL, aunque la inestabilidad sigue presente.

RM vs RM




Figura 32: Convergencia RM vs RM en Blotto.




Figura 33: Reward y Comparación política promedio para RM vs RM.

En el enfrentamiento entre RM y RM en Blotto, ambos algoritmos logran aproximar la estrategia dominante de manera rápida y estable. Las recompensas oscilan alrededor de cero.

JAL-AM vs JAL-AM

Convergencia: JAL-AM vs JAL-AM — Blotto (S=6, N=3)




Figura 34: Convergencia JAL-AM vs JAL-AM en Blotto.




Figura 35: Reward y Comparación política promedio para JALAM vs JALAM.

En esta partida, ambos agentes juegan muy mal, con recompensas oscilando en cero, pero sin mostrar una convergencia clara hacia la estrategia dominante.

Esto sugiere que el modelado explícito del oponente en JAL-AM no es suficiente para garantizar una convergencia estable en un entorno con un espacio de acciones más complejo como Blotto, especialmente cuando ambos agentes están aprendiendo simultáneamente.




Figura 36: Trayectoria de política en simplex.

La figura muestra la rápida convergencia que se da hacia la estrategia dominante (2, 2, 2) para ambos agentes, lo que es consistente con los resultados observados en los gráficos de recompensa y comparación de políticas.

Conclusiones

En el ambiente de Blotto, los algoritmos FP y RM demostraron una capacidad sólida para converger hacia la estrategia dominante, con RM mostrando una convergencia más rápida y estable.

Por otro lado, IQL presentó un comportamiento inestable debido a la no estacionariedad del entorno, aunque logró adaptarse parcialmente a oponentes aleatorios. JAL-AM mostró una mejora respecto a IQL al incorporar modelado del oponente, aunque todavía presentó cierta inestabilidad. En general, los resultados reflejan las fortalezas y limitaciones de cada algoritmo en un entorno competitivo con un espacio de acciones más complejo, destacando la importancia de considerar la naturaleza del juego y el tipo de oponentes al seleccionar un enfoque de aprendizaje multiagente.

4.3. Battle-Of-Sexes

FP vs FP




Figura 37: Convergencia FP vs FP en Battle of Sexes.




Figura 38: Histograma de acciones para FP vs FP en Battle of Sexes.




Figura 39: Reward y Comparación política promedio para FP vs FP.

En el experimento de FP vs FP en Battle of Sexes, ambos agentes convergen hacia uno de los dos equilibrios de Nash puros, donde ambos eligen la misma acción (Cine o Partido).

El reward 1.25 (entre 0 y 2) con banda ancha sugiere que en distintas corridas/episodios los agentes coordinan en diferentes equilibrios puros, o hay oscilación transitoria antes de converger.

Según podemos ver en el histograma, ambos agentes terminan eligiendo la misma acción con alta frecuencia, lo que indica que logran coordinarse exitosamente a la hora de buscar un equilibrio.

FP vs Random




Figura 40: Convergencia FP vs Random en Battle of Sexes.




Figura 41: Histograma de acciones para FP vs Random en Battle of Sexes.

El agente random no adapta su comportamiento, por lo que FP lo "leez encuentra la mejor respuesta pura. Esto muestra que FP es un algoritmo racional ante oponentes estáticos.

la curva es suave y monótona, lo que refleja que FP necesita acumular suficiente evidencia estadística antes de comprometerse con la acción dominante.

Según los histogramas, el agente Random elige ambas acciones con frecuencia similar, mientras que el agente FP termina eligiendo consistentemente la acción que le da mayor recompensa frente a un oponente impredecible.

FP vs RM

Acciones seleccionadas: FP vs RM — BoS




Figura 42: Histograma de acciones para FP vs RM en Battle of Sexes.




Figura 43: Reward y Comparación política promedio para FP vs RM en Battle of Sexes.

Observando la convergencia con respecto a la política promedio, se ve que ambos agentes convergen rápidamente al equilibrio (cine, cine).

Comparado con FP vs FP (1.25), el reward es significativamente mayor, como así la convergencia más rápida. Esto ocurre porque el oponente no adapta su estrategia, permitiendo que `agent_0` explote consistentemente la mejor respuesta pura (Cine).

IQL vs IQL




Figura 44: Convergencia IQL vs IQL en Battle of Sexes.




Figura 45: Histograma de acciones para IQL vs IQL en Battle of Sexes.




Figura 46: Reward y Comparación política promedio para IQL vs IQL en Battle of Sexes.

En el experimento de IQL vs IQL en Battle of Sexes, ambos agentes presentan un comportamiento inestable. Aparente contradicción con el gráfico de convergencia

El histograma muestra Cine dominante, mientras que el gráfico de política termina cerca de 0. La explicación: el histograma acumula todas las rondas — y durante la fase temprana (rondas 1–500), ambos agentes jugaron Cine frecuentemente con alta exploración (epsilon alto). Esas primeras rondas aportan la mayoría de los 9791 Cines, aunque la política final apunte a Partido.

IQL vs Random




Figura 47: Convergencia IQL vs Random en Battle of Sexes.




Figura 48: Histograma de acciones para IQL vs Random en Battle of Sexes.

IQL identifica correctamente que Cine es la mejor respuesta ante un oponente Random, pero no garantiza convergencia estable — la exploración y la tasa de aprendizaje generan oscilación post-convergencia.

RM vs RM




Figura 49: Convergencia RM vs RM en Battle of Sexes.




Figura 50: Histograma de acciones para RM vs RM en Battle of Sexes.




Figura 51: Reward y Comparación política promedio para RM vs RM en Battle of Sexes.

RM vs RM converge rápidamente y de forma estable a un equilibrio de Nash puro, logrando coordinación perfecta.

El histograma muestra que ambos agentes eligen la misma acción (Cine) con alta frecuencia, lo que indica una coordinación exitosa.

La Reward promedio es un número cercano a 1.4, lo cual es consistente ya que es un número entre 1 y 2, dependiendo de la frecuencia con la que ambos agentes elijan Cine (2) o Partido (1).

RM vs Random




Figura 52: Convergencia RM vs Random en Battle of Sexes.




Figura 53: Histograma de acciones para RM vs Random en Battle of Sexes.

Este experimento es el que muestra convergencia más rápida de todas, La rigidez del oponente aleatorio (0.5 fijo) convierte el problema de aprendizaje en casi trivial para RM.

El histograma muestra que el agente RM elige consistentemente la acción que le da mayor recompensa frente a un oponente impredecible, mientras que el agente aleatorio elige ambas acciones con frecuencia similar. Esto demuestra la capacidad de RM para adaptarse a diferentes tipos de oponentes, aunque en este caso el agente aleatorio no representa un desafío estratégico significativo.

JAL-AM vs JAL-AM




Figura 54: Convergencia JALAM vs JALAM en Battle of Sexes.




Figura 55: Histograma de acciones para JALAM vs JALAM en Battle of Sexes.




Figura 56: Reward y Comparación política promedio para JALAM vs JALAM en Battle of Sexes.

JAL-AM en BoS exhibe una inestabilidad muy alta debido a la naturaleza del juego y a la dinámica de aprendizaje. Aunque ambos agentes logran adaptarse mutuamente, las recompensas oscilan considerablemente, lo que sugiere que no logran coordinarse de manera consistente en uno de los equilibrios puros.

El histograma muestra que ambos agentes eligen ambas acciones con frecuencia, lo que indica una falta de coordinación estable. La Reward promedio es un número cercano a 1 pero con mucha variabilidad, lo que refleja la oscilación entre los equilibrios puros.

Comparativa de rewards




Figura 57: Comparativa de rewards para todos los enfrentamientos en Battle of Sexes.

Todos los experimentos producen rewards ≥ 1.20 para ambos agentes, muy por encima del equilibrio mixto (línea azul 0.667). Esto confirma que todos los algoritmos logran algún grado de coordinación en Equilibrios de Nash puros, que son más eficientes que mezclar aleatoriamente.

Considerando las rewards para ambos agentes, destacan RM vs FP y RM vs RM, como los experimentos que recolectan más rewards en forma combinada.

Conclusiones

En el ambiente de Battle of Sexes, los algoritmos FP y RM demostraron una capacidad sólida para converger hacia equilibrios de Nash puros, con RM mostrando una convergencia más rápida y estable. Por otro lado, IQL presentó un comportamiento inestable debido a la no estacionariedad del entorno, aunque logró adaptarse parcialmente a oponentes aleatorios. JAL-AM mostró una mejora respecto a IQL al incorporar modelado del oponente, aunque todavía presentó cierta inestabilidad.

4.4. Chicken

FP vs Random




Figura 58: Convergencia FP vs Random en Chicken.




Figura 59: Histograma de acciones para FP vs Random en Chicken.

FP aprende a "no ceder" porque sabe que el oponente aleatorio cederá el 50

El histograma muestra que el agente Random elige ambas acciones con frecuencia similar, mientras que el agente FP termina eligiendo consistentemente la acción de "no ceder", lo que demuestra la capacidad de FP para adaptarse a diferentes tipos de oponentes.

FP vs FP




Figura 60: Convergencia FP vs FP en Chicken.




Figura 61: Histograma de acciones para FP vs FP en Chicken.




Figura 62: Reward y Comparación política promedio para FP vs FP en Chicken.

FP converge rápidamente a un equilibrio puro (**agente_0** cede y **agente_1** no cede), el equilibrio se construye en forma coordinada por ambos agentes.

En terminos de reward acumuladas, la reward 4.5 dentro de un intervalo entre 2 y 7, lo cual tiene sentido porque son las ganancias de los agentes cuando se alcanzan equilibrios puros.

El histograma muestra una marcada tendencia del **agente_0** a elegir ceder del **agente_1** a elegir "no ceder".

RM vs Random




Figura 63: Convergencia RM vs Random en Chicken.




Figura 64: Histograma de acciones para RM vs Random en Chicken.

RM elije ceder, ya que el agente aleatorio al sortear ceder y no ceder al 50

En el histograma se ve que RM elige consistentemente la acción de "no ceder", mientras que el agente aleatorio elige ambas acciones con frecuencia similar.

RM vs RM




Figura 65: Convergencia RM vs RM en Chicken.




Figura 66: Histograma de acciones para RM vs RM en Chicken.




Figura 67: Reward y Comparación política promedio para RM vs RM en Chicken.

La convergencia de los agentes fue buena(tendiendo a uno de los equilibrios puros), aunque con más oscilación que FP vs FP.

Esto también se ve reflado en las rewards, en donde el intervalo va de 1 a 6, a fiderencia del 2 a 7 en FP, y esto se debe a las oscilaciones anteriormente mencionadas, las que reducen la tasa de rewards, por ejemplo en escenarios de S y S.

IQL vs IQL




Figura 68: Histograma de acciones para IQL vs IQL en Chicken.




Figura 69: Reward y Comparación política promedio para IQL vs IQL en Chicken.

Los agentes IQL nunca converge a equilibrios ni puros ni mixtos, ya que cada agente tiene a elegir L, pero la ganancia es considerablemente alta, ya que (L,L) paga 6 a cada agente.

De todas maneras, IQL falla en su objetivo de alcanzar un equilibrio.

JAL-AM vs JAL-AM




Figura 70: Histograma de acciones para JAL-AM vs JAL-AM en Chicken.




Figura 71: Reward y Comparación política promedio para JAL-AM vs JAL-AM en Chicken.

JAL-AM en Chicken el **agente_0** aprende a ser consistentemente agresivo (L), **agente_1** mezcla hacia S. Sin embargo, no converge a ningún equilibrio de Nash puro ni al mixto, y el reward oscila permanentemente. La modelización de acciones conjuntas crea la asimetría observada, pero el mecanismo de promedio no logra estabilizar el sistema en un equilibrio.

Comparación de rewards




Figura 72: Comparación de rewards para JAL-AM vs JAL-AM en Chicken.

En Chicken, la capacidad de romper la simetría y asignar acciones diferenciadas (L y S) determina el reward. FP lo logra deterministamente y de forma equitativa; IQL lo logra caóticamente pero con buen resultado; RM y JALAM lo logran pero de forma asimétrica, siempre favoreciendo a agente_1.

Juegos cruzados




Figura 73: Juegos cruzados en Chicken.

En los juegos cruzados, FP y RM logran coordinarse exitosamente, mientras que IQL y JAL-AM presentan comportamientos más erráticos. Esto resalta la importancia de la estabilidad y la capacidad de adaptación en entornos multiagente competitivos.

Conclusiones

En el ambiente de Chicken, los algoritmos FP y RM demostraron una capacidad sólida para converger hacia equilibrios de Nash puros, con FP mostrando una convergencia más rápida y estable.

Por otro lado, IQL presentó un comportamiento inestable debido a la no estacionariedad del entorno, aunque logró adaptarse parcialmente a oponentes aleatorios. JAL-AM mostró una mejora respecto a IQL al incorporar modelado del oponente, aunque todavía presentó cierta inestabilidad.

En general, los resultados reflejan las fortalezas y limitaciones de cada algoritmo en un entorno competitivo con múltiples equilibrios, destacando la importancia de considerar la naturaleza del juego

y el tipo de oponentes al seleccionar un enfoque de aprendizaje multiagente.

4.5. Rock-Paper-Scissors

En este ambiente se evaluó si los algoritmos logran aproximarse a la estrategia mixta uniforme esperada y mantener recompensas promedio cercanas a cero. Para ello, se ejecutaron experimentos de *self-play*, enfrentando a cada algoritmo consigo mismo, y experimentos de *cross-play*, enfrentando algoritmos distintos entre sí y contra un agente aleatorio (Random).

FP vs FP




Figura 74: FP vs FP en RPS.




Figura 75: Trayectoria de políticas para FP vs FP.

En self-play, FP muestra el comportamiento clásico esperado en RPS. Las recompensas oscilan alrededor de cero durante todo el entrenamiento, algo consistente con un juego de suma cero donde ningún agente puede explotar sistemáticamente al otro.

La política instantánea nunca converge completamente, sino que continúa oscilando alrededor del equilibrio de Nash. Sin embargo, la política promedio acumulada sí converge claramente hacia $(1/3, 1/3, 1/3)$.

Esto también puede observarse en las trayectorias de la política, donde ambos agentes generan espirales alrededor del centro del triángulo y terminan estabilizándose cerca del equilibrio mixto.

RM vs RM




Figura 76: RM vs RM en RPS.




Figura 77: Trayectoria de políticas para RM vs RM en el simplex.

RM mostró un comportamiento similar al de FP, ya que cuenta con oscilaciones de la política instantánea y la política promedio acumulada converge rápidamente hacia el equilibrio de Nash.

En la trayectoria de la política, se observa que las trayectorias permanecen concentradas cerca

del centro, reflejando la propiedad de no-arrepentimiento del algoritmo.

IQL vs IQL




Figura 78: IQL vs IQL en RPS.

IQL fue el algoritmo más inestable en RPS. Aunque la política promedio acumulada logra acercarse parcialmente al equilibrio de Nash, la política instantánea presenta fluctuaciones importantes durante todo el entrenamiento.

Esto ocurre porque cada agente aprende asumiendo que el entorno es estacionario, cuando en realidad la política del oponente cambia continuamente.

Aun así, el promedio acumulado termina relativamente cerca de $(1/3, 1/3, 1/3)$, aunque con bastante más varianza.

JAL-AM vs JAL-AM




Figura 79: JAL-AM vs JAL-AM en RPS.

JAL-AM obtuvo resultados considerablemente mejores que IQL. Al incorporar modelado explícito de las acciones del oponente, el algoritmo logra reducir parcialmente los efectos de la no estacionariedad. Las oscilaciones de la política instantánea son menores y la política promedio acumulada converge más rápidamente hacia $(1/3, 1/3, 1/3)$ que en IQL. Además, la trayectoria de la estrategia mixta evidencia una mayor concentración alrededor del equilibrio, aunque todavía con más variabilidad que FP o RM.

De todas formas, no se esperaba que JAL-AM tenga un comportamiento perfectamente estable en RPS, dado que Rock-Paper-Scissors es un juego de suma cero donde la mejor respuesta cambia constantemente dependiendo de la política del oponente. En este tipo de entornos, modelar al oponente no garantiza convergencia estable, ya que ambos agentes continúan adaptándose mutuamente todo el tiempo.

FP vs RM




Figura 80: FP vs RM en RPS.




Figura 81: Trayectoria de políticas para FP vs RM en el simplex.

Cuando FP y RM compiten entre sí, ambos logran aproximar correctamente el equilibrio de Nash.

Las recompensas permanecen centradas alrededor de cero y las políticas promedio convergen

rápidamente hacia el equilibrio de Nash.

Puede observarse que RM parece adaptarse ligeramente más rápido durante las primeras iteraciones, mientras que FP mantiene oscilaciones más amplias. Sin embargo, en el largo plazo ambos terminan comportándose de forma muy similar.

La trayectoria de la estrategia mixta muestra además una diferencia interesante entre ambos algoritmos. FP genera movimientos más suaves y graduales alrededor del equilibrio, mientras que RM presenta curvas más pronunciadas y en algunos momentos se aleja más del centro del triángulo.

Esto ocurre porque RM ajusta directamente sus probabilidades utilizando regrets acumulados. En ciertos momentos, pequeñas diferencias en los regrets pueden provocar cambios más agresivos en la política, aumentando considerablemente la probabilidad de algunas acciones antes de volver a estabilizarse.

FP, en cambio, responde utilizando la frecuencia promedio observada del oponente, generando trayectorias más progresivas y menos abruptas.

Aun así, aunque RM a veces se aleje más instantáneamente del equilibrio, su política promedio acumulada converge más rápido que FP. Esto explica por qué RM logra mantenerse más cerca del equilibrio de Nash en promedio a pesar de presentar movimientos más curvos durante el entrenamiento.

Además, comparando este experimento con RM vs RM, puede observarse que RM parece comportarse de forma más estable cuando juega contra FP. Una posible explicación es que FP genera dinámicas más suaves y predecibles, ya que actualiza sus estrategias utilizando frecuencias promedio acumuladas. Esto produce un entorno menos agresivo para RM que cuando enfrenta otro RM, donde ambos agentes realizan ajustes rápidos basados en regrets acumulados y generan oscilaciones más fuertes simultáneamente.

Como consecuencia, al enfrentarse contra FP, RM parece estabilizarse más rápido y mantener

trayectorias más concentradas alrededor del equilibrio.

Todos los algoritmos vs agente aleatorio




Figura 82: Reward promedio enfrentando a un agente aleatorio.

Todos los algoritmos logran adaptarse relativamente bien frente a un agente aleatorio.

FP obtiene los mejores resultados, lo cual tiene sentido dado que modela explícitamente la frecuencia de acciones del oponente y responde con mejores respuestas puras.

RM también logra explotar correctamente al agente aleatorio. En cambio, IQL y JAL-AM presentan resultados más variables debido a la exploración y a la naturaleza más inestable del aprendizaje por refuerzo multiagente.

Observaciones




Figura 83: Distancia L1 al equilibrio de Nash.

Los experimentos realizados en Rock-Paper-Scissors muestran diferencias claras entre los algoritmos basados en teoría de juegos (FP y RM) y los algoritmos de aprendizaje por refuerzo multiagente (IQL y JAL-AM).

FP y RM fueron los algoritmos que mejor lograron aproximar el equilibrio de Nash del juego. En ambos casos, la política promedio acumulada converge claramente hacia la estrategia mixta uniforme $(1/3, 1/3, 1/3)$ y las recompensas permanecen centradas alrededor de cero, comportamiento esperable en un juego de suma cero.

RM fue el algoritmo más estable de todos los experimentos realizados. Las oscilaciones de sus políticas fueron menores y la convergencia hacia el equilibrio resultó más rápida que en FP. Esto también puede observarse en las trayectorias de la estrategia mixta, donde RM permanece más concentrado alrededor del centro del triángulo.

FP, por otro lado, mostró un comportamiento más gradual y suave. Sus trayectorias generan espirales más amplias alrededor del equilibrio, aunque igualmente convergen correctamente en promedio.

IQL fue claramente el algoritmo más inestable. Las políticas instantáneas continuaron fluctuando fuertemente incluso luego de miles de episodios, reflejando el problema de no estacionariedad típico del aprendizaje multiagente. Al asumir implícitamente que el entorno es estacionario, IQL tiene dificultades para adaptarse correctamente cuando el oponente también está aprendiendo y modificando continuamente su estrategia.

JAL-AM logró mejorar considerablemente respecto a IQL gracias al modelado explícito del oponente. Las políticas presentaron oscilaciones permanentes, algo esperable en un juego competitivo de suma cero como RPS, sin embargo, las trayectorias resultan más estables y cercanas al equilibrio de Nash que en IQL.

Finalmente, los experimentos muestran cómo pequeños cambios en la forma de modelar al oponente producen diferencias importantes en estabilidad y convergencia dentro de entornos multi-agente competitivos.

4.6. Three-Player Game

En Three-Player Game se evaluó el comportamiento de los algoritmos sobre todas las configuraciones del ambiente. El objetivo fue analizar si las políticas aprendidas se acercan a los equilibrios de Nash descritos previamente y cómo cambia la convergencia cuando la matriz de pagos introduce múltiples equilibrios, indiferencias o incentivos de desviación.

A diferencia de RPS, donde el equilibrio es mixto y las trayectorias pueden oscilar alrededor del centro del simplex, en estos juegos se espera que los agentes concentren su probabilidad en acciones de equilibrio cuando existe un perfil puro claro. En la configuración 1, por ejemplo, esto corresponde al perfil (B, R, W) : `agent_0` debe asignar probabilidad cercana a 1 a B , `agent_1` a R y `agent_2` a

W.

Para la configuración 1 se evaluaron FP, RM, entrenamientos mixtos entre ambos, IQL y JAL-AM. Para las configuraciones 2, 3 y 4 se evaluaron FP, RM y combinaciones mixtas entre ambos algoritmos.

FP y RM en self-play




Figura 84: Entrenamiento de Fictitious Play en Three-Player Game.




Figura 85: Entrenamiento de Regret Matching en Three-Player Game.

FP y RM convergen de manera clara al equilibrio puro. En ambos casos, la recompensa promedio se estabiliza rápidamente en los pagos del equilibrio (3, 4, 2) y la política promedio acumulada de cada agente se aproxima a probabilidad 1 en la acción correspondiente al equilibrio.

RM presenta una convergencia levemente más rápida y concentrada que FP. Esto es consistente con el uso de arrepentimiento acumulado: una vez que la acción de equilibrio genera mejores resultados frente al comportamiento observado de los demás agentes, la probabilidad asignada a esa acción aumenta de forma directa.

Entrenamientos mixtos entre FP y RM

2FP+1RM $\times$ 3 — Three-Player Game (Config 1)




Figura 86: Entrenamiento mixto con dos agentes FP y un agente RM en Three-Player Game.

2RM+1FP $\times$ 3 — Three-Player Game (Config 1)




Figura 87: Entrenamiento mixto con dos agentes RM y un agente FP en Three-Player Game.

Los entrenamientos mixtos mantienen el mismo comportamiento observado en self-play. Tanto en la configuración con dos agentes FP y uno RM como en la configuración con dos agentes RM y uno FP, las políticas convergen al perfil (B, R, W) y las recompensas terminan en $(3, 4, 2)$.

Esto sugiere que, para este juego, la combinación de FP y RM no introduce inestabilidad relevante. Como el equilibrio es puro y todos los agentes reciben señales consistentes al acercarse a ese perfil, ambos algoritmos terminan reforzando la misma solución estratégica.

IQL y JAL-AM




Figura 88: Entrenamiento de IQL en Three-Player Game.




Figura 89: Entrenamiento de JAL-AM en Three-Player Game.

IQL logra recompensas promedio cercanas a las del equilibrio, pero sus políticas no se concentran completamente en la acción de Nash. La probabilidad de la acción de equilibrio queda alrededor de valores intermedios y presenta oscilaciones, reflejando nuevamente el problema de no estacionariedad.

En JAL-AM Las recompensas promedio también están cercanas al equilibrio pero con mucha varianza, pero las políticas siguen sin converger de forma limpia a probabilidad 1 en las acciones de equilibrio. Esto muestra que una recompensa alta no implica necesariamente estar cerca de un equilibrio de Nash estable.

Distancia al equilibrio de Nash




Figura 90: Distancia L1 al equilibrio de Nash en Three-Player Game.

La comparación de distancia L1 confirma las diferencias entre algoritmos. FP, RM y los entrenamientos mixtos alcanzan distancias cercanas a cero para los tres agentes, o que significa que todos los agentes logran acercarse fuertemente al equilibrio de Nash.

Configuración 2.

En las gráficas, las etiquetas de la forma *Agente 0-T* o *Agente 1-R* indican la probabilidad que asigna cada agente a una acción concreta. Por ejemplo, *Agente 0-T* representa la probabilidad de que **agent_0** elija la acción *T* (*Top*), mientras que *Agente 0-B* corresponde a la acción *B* (*Bottom*). De forma análoga, *Agente 1-L* y *Agente 1-R* representan las acciones *L* (*Left*) y *R* (*Right*) de **agent_1**, y *Agente 2-W* y *Agente 2-E* representan las acciones *W* (*West*) y *E* (*East*) de **agent_2**.


FP $\times$ 3 — Three-Player Game (Config 2)

Figura 91: Entrenamiento de Fictitious Play en Three-Player Game, configuración 2.


RM $\times$ 3 — Three-Player Game (Config 2)

Figura 92: Entrenamiento de Regret Matching en Three-Player Game, configuración 2.




Figura 93: Entrenamiento mixto con dos agentes FP y un agente RM en Three-Player Game, configuración 2.

En las curvas de políticas, una línea cerca de 1 significa que esa acción se elige casi siempre, y una línea cerca de 0 significa que esa acción casi no se elige. Por eso, en esta configuración se espera que *Agente 0-B* tienda a 1 y *Agente 0-T* tienda a 0, mientras que *Agente 1-L* tienda a 1 y *Agente 1-R* tienda a 0. Ese comportamiento indica que los dos primeros agentes aprendieron la parte común de los equilibrios de Nash: (B, L) .

Todos los entrenamientos terminan con recompensas promedio finales cercanas a $(1, 1, 1)$. Esto muestra que FP, RM y las combinaciones mixtas convergen hacia el conjunto de equilibrios de Nash de la configuración 2, aunque no hacia los perfiles de mayor recompensa conjunta. En particular, *agent_2* puede repartir probabilidad entre *W* y *E* sin salir del equilibrio, como se explicó en la descripción del ambiente. También se realizaron varios entrenamientos cruzados combinando FP y RM en distintos agentes. Como todos mostraron el mismo comportamiento cualitativo y recompensas finales similares, se incluye una única gráfica mixta representativa.

Configuración 3.




Figura 94: Entrenamiento de Fictitious Play en Three-Player Game, configuración 3.




Figura 95: Entrenamiento de Regret Matching en Three-Player Game, configuración 3.




Figura 96: Entrenamiento mixto con dos agentes FP y un agente RM.

En esta configuración, la interpretación de las curvas es la misma que antes, cada línea representa la probabilidad asignada por un agente a una acción. Sin embargo, las políticas no se concentran de forma tan clara como en la configuración 2. Esto es consistente con la estructura del ambiente, dado que, existen varias zonas estratégicamente estables, pero ninguna combina una recompensa alta y balanceada para todos los agentes.

Las recompensas finales reflejan esta dificultad, FP, RM y el entrenamiento mixto no convergen a un perfil dominante con recompensa alta para todos, sino a comportamientos más inestables y desbalanceados. Que algunas de las políticas no lleguen limpiamente a 1 no implica necesariamente que el entrenamiento sea incorrecto; puede indicar que distintas ejecuciones se estabilizan en regiones diferentes o que los agentes alternan entre respuestas con incentivos similares.

Configuración 4.




Figura 97: Entrenamiento de Fictitious Play en Three-Player Game, configuración 4.




Figura 98: Entrenamiento de Regret Matching en Three-Player Game, configuración 4.




Figura 99: Entrenamiento mixto con dos agentes FP y un agente RM en Three-Player Game, configuración 4.

En la configuración 4, las políticas se estabilizan con mayor claridad que en la configuración 3. En las curvas se observa que *Agente 0-B* y *Agente 1-L* concentran la mayor parte de la probabilidad, mientras que *Agente 0-T* y *Agente 1-R* pierden peso. Para *agent_2*, la probabilidad puede quedar repartida entre las acciones equivalentes del equilibrio, por lo que no es necesario que una única acción llegue exactamente a 1.

A pesar de la asimetría de la matriz de pagos, FP, RM y el entrenamiento mixto terminan con recompensas promedio cercanas a $(1, 1, 1)$. Esto sugiere que los algoritmos logran identificar nuevamente una zona estable del juego.

Observaciones

Los resultados de Three-Player Game muestran que la estructura del juego tiene un efecto directo sobre la convergencia. En la configuración 1, donde existe un equilibrio puro claro en (B, R, W) , FP y RM identifican rápidamente el perfil estable y concentran sus políticas en las acciones de equilibrio. En la configuración 2 ocurre algo similar, aunque existe un perfil con mayor recompensa

conjunta, los algoritmos terminan convergiendo a perfiles de equilibrio con pagos $(1, 1, 1)$ porque son estratégicamente estables.

La configuración 3 muestra el caso más difícil. Al incorporar una tercera acción para `agent_2` y no presentar un equilibrio puro atractivo, las recompensas quedan desbalanceadas y aparecen comportamientos más oscilatorios. En cambio, la configuración 4, aunque también es más grande y asimétrica, permite que FP, RM y las combinaciones mixtas vuelvan a estabilizarse cerca de recompensas $(1, 1, 1)$.

En conjunto, estos experimentos muestran que FP y RM son robustos cuando existe una estructura de equilibrio clara, incluso al mezclar ambos algoritmos entre agentes. Sin embargo, cuando la matriz de pagos introduce incentivos de desviación más fuertes o elimina perfiles puros atractivos, como ocurre en la configuración 3, la convergencia deja de ser limpia y la recompensa promedio por sí sola no alcanza para describir completamente la estabilidad estratégica.

4.7. Foraging

En esta sección se presentan los entrenamientos realizados sobre las configuraciones de Foraging descritas previamente. El objetivo es comparar cómo evolucionan IQL y JAL-AM en ambientes secuenciales con estado, observando la recompensa promedio, la cantidad de pasos necesarios para completar los episodios y el reparto de recompensa entre agentes.

Configuraciones 0: grilla 5x5 con dos agentes




Figura 100: Entrenamiento de IQL en Foraging 5x5 con 2 agentes.




Figura 101: Episodio entrenado con IQL en Foraging 5x5.




Figura 102: Entrenamiento de JAL-AM en Foraging 5x5 con 2 agentes.




Figura 103: Episodio entrenado con JAL-AM en Foraging 5x5.

En la grilla 5x5 ambos algoritmos aprenden rápidamente a llegar a la comida, sin embargo se observa un comportamiento desbalanceado entre ambos agentes, durante las primeras iteraciones las recompensas son relativamente similares, pero rápidamente **agent_0** incrementa su recompensa promedio por episodio y se estabiliza en valores cercanos a 0.7 – 0.8. En cambio, **agent_1** reduce progresivamente su recompensa y permanece en valores considerablemente menores.

Además podemos ver que, JAL-AM muestra una evolución algo más estable que IQL, aunque no elimina el desbalance.

Al observar la ejecución de la política entrenada, se aprecia que ambos agentes se desplazan de forma coordinada hacia la comida y que el recurso se recolecta exitosamente en pocos pasos.

Configuraciones 1: grilla 8x8 con dos agentes




Figura 104: Entrenamiento de IQL en Foraging 8x8 con 2 agentes.




Figura 105: Episodio entrenado con IQL en Foraging 8x8.




Figura 106: Entrenamiento de JAL-AM en Foraging 8x8 con 2 agentes.




Figura 107: Episodio entrenado con JAL-AM en Foraging 8x8.

En la grilla 8x8 se repite la misma dinámica general, pero el aprendizaje es más lento y variable porque el espacio de estados es mayor. IQL aprende trayectorias útiles, aunque mantiene una distribución de recompensas desbalanceada. JAL-AM suaviza las curvas y reduce parcialmente la diferencia entre agentes, pero tampoco logra un reparto completamente equilibrado. En ambos casos, la política entrenada muestra que los agentes se desplazan hacia la comida y logran recolectarla.

Configuración 2: grilla 8x8 con tres agentes




Figura 108: Entrenamiento de IQL en Foraging 8x8 con 3 agentes.




Figura 109: Episodio entrenado con IQL en Foraging 8x8 con 3 agentes.




Figura 110: Entrenamiento de JAL-AM en Foraging 8x8 con 3 agentes.




Figura 111: Episodio entrenado con JAL-AM en Foraging 8x8 con 3 agentes.

Con tres agentes aparece una cooperación, donde dos agentes suelen coordinarse alrededor del recurso y un tercero queda relegado. Esto ocurre tanto con IQL como con JAL-AM. JAL-AM produce curvas algo más suaves, pero no elimina el desbalance entre agentes.

La ejecución de la política entrenada muestra un comportamiento interesante, en el segundo step `agent_2` ejecuta `NONE`, lo que sugiere que aprendió a esperar a su compañero antes de recolectar la comida. De esta forma, la recolección puede ocurrir de manera coordinada y con recompensa compartida.

Equipos mixtos en grilla 8x8 con tres agentes




Figura 112: Entrenamiento de JAL-AM x2 + IQL x1 en Foraging.




Figura 113: Episodio con JAL-AM x2 + IQL x1.

También se realizaron otros experimentos con equipos mixtos, cambiando la proporción de agentes IQL y JAL-AM. Como los resultados obtenidos fueron muy similares, se muestra únicamente el caso JAL-AM x2 + IQL x1 como ejemplo representativo. En general, la mezcla de algoritmos no modifica sustancialmente la dinámica no cooperativa de tres agentes, la coordinación efectiva emerge entre algunos miembros del equipo y un agente puede quedar con baja recompensa. Esto indica que el algoritmo utilizado no es el único factor determinante; la posición relativa, la exploración temprana y las trayectorias aprendidas también influyen fuertemente.

Configuración 3: grilla 8x8 cooperativa con tres agentes




Figura 114: Entrenamiento de IQL en Foraging cooperativo 8x8 con 3 agentes.




Figura 115: Episodio entrenado con IQL en Foraging cooperativo.




Figura 116: Ejecución de la política entrenada con JAL-AM en Foraging cooperativo.




Figura 117: Episodio entrenado con JAL-AM en Foraging cooperativo.

En la configuración cooperativa cambia significativamente la dinámica del aprendizaje. Tanto IQL como JAL-AM convergen rápido y muestran recompensas estables. **agent_0** recibe aproximadamente 0.5, mientras que **agent_1** y **agent_2** reciben alrededor de 0.25. Esta diferencia no indica dominancia, sino un reparto esperado, dado que **agent_0** tiene nivel 2 y los otros agentes nivel 1, por lo que todos reciben la recompensa correspondiente a su contribución.

A diferencia de las configuraciones anteriores, no aparece un agente completamente excluido. Como la comida requiere cooperación para ser recolectada, todos los agentes se desplazan hacia el recurso y participan del objetivo compartido. La ejecución entrenada requiere más pasos que los escenarios no cooperativos, pero esto refleja la necesidad de coordinar posiciones antes de ejecutar LOAD.

Entrenamientos cruzados.




Figura 118: Entrenamiento de JAL-AM x2 + IQL x1 en Foraging cooperativo.




Figura 119: Ejecución de la política entrenada con JAL-AM x2 + IQL x1.

También se evaluaron entrenamientos cruzados combinando IQL y JAL-AM. Como ambos cruces presentan resultados similares, se muestra JAL-AM x2 + IQL x1 como caso representativo. En el ambiente cooperativo, los equipos mixtos mantienen el reparto esperado por niveles, además de la gráfica de Cantidad de pasos requeridos para completar el episodio, se observa que necesitan menos pasos que los equipos homogéneos, lo que sugiere trayectorias más eficientes hacia el objetivo compartido.

Observaciones

Los experimentos de Foraging muestran que la estructura del ambiente tiene un impacto central sobre el comportamiento emergente. En escenarios no cooperativos o mixtos, IQL y JAL-AM logran aprender trayectorias efectivas, pero las recompensas suelen distribuirse de forma desigual entre agentes. Esto ocurre especialmente cuando algunos agentes llegan antes al recurso o quedan mejor posicionados durante el entrenamiento.

Este comportamiento es consistente con la definición teórica de los agentes. En IQL, cada agente aprende de forma independiente, por lo que una ventaja temprana de posición o exploración puede reforzarse con el tiempo. JAL-AM reduce parcialmente este problema al modelar las acciones de los demás, podemos ver como tiende a producir curvas más estables, pero sin embargo esto no elimina la no estacionariedad ni garantiza un reparto equilibrado.

Las gráficas de pasos requeridos muestran que, al comienzo del entrenamiento, los episodios suelen estar por encima de los 50 pasos, lo que indica que los agentes todavía no logran llegar a la comida de forma eficiente, pero rápidamente se reduce significativamente la cantidad de pasos necesarios para llegar siempre al recurso.

Las visualizaciones de las políticas entrenadas ayudan a interpretar mejor este resultado. Permiten comprobar que los agentes con mayor recompensa son los que ejecutan **LOAD** del recurso, pero también muestran que los agentes con menor recompensa en la mayoría de los casos se desplazan correctamente hacia la comida, mostrando que la política que aprendieron es una política útil.

Además, para una misma configuración los agentes comienzan siempre desde las mismas posiciones iniciales porque se utiliza el mismo *seed*. Esto puede favorecer sistemáticamente a un agente si queda mejor ubicado respecto a la comida. Se realizaron pruebas adicionales rotando el *seed* en cada iteración para reducir este sesgo, pero los resultados fueron peores y el desbalance entre agentes se mantuvo.

Cuando el entorno fuerza la cooperación, las diferencias entre agentes se reducen y emerge un comportamiento coordinado más claro. En este caso, la necesidad de actuar conjuntamente domina la dinámica del aprendizaje y favorece políticas donde todos los agentes participan de la recolección del recurso. Además, los experimentos cruzados en el ambiente cooperativo necesitaron menos pasos que aquellos donde todos los agentes utilizaban el mismo algoritmo, lo que sugiere que combinar IQL y JAL-AM puede favorecer trayectorias más eficientes hacia el objetivo compartido. Esto puede deberse a que ambos algoritmos introducen sesgos de aprendizaje complementarios, donde IQL tiende a aprender trayectorias directas a partir de su propia recompensa, mientras que JAL-AM incorpora información sobre el comportamiento esperado de los demás agentes. En un entorno cooperativo, esta combinación puede facilitar que los agentes se ajusten mejor entre sí y reduzcan movimientos innecesarios. Esto nos permite concluir que tanto IQL como JAL-AM aprenden una política adecuada.

4.8. Cournot

En los experimentos de Cournot se evaluó si los algoritmos logran aproximar el equilibrio de Nash en un juego de competencia por cantidades. Con los parámetros utilizados, el equilibrio de Nash para dos firmas se encuentra en $q^* = 4$ y una ganancia de 32 por firma. Para tres firmas, el equilibrio pasa a $q^* = 3$ y la ganancia esperada por firma baja a 18, ya que la producción total del mercado aumenta y el precio de equilibrio disminuye.

Cournot con dos jugadores: algoritmos basados en teoría de juegos (RM y FP)




Figura 120: Convergencia de Regret Matching en Cournot con 2 jugadores.




Figura 121: Convergencia de Fictitious Play en Cournot con 2 jugadores.

Tanto Regret Matching como Fictitious Play logran aproximar correctamente el equilibrio de Nash.

En ambos algoritmos, las cantidades elegidas por las firmas terminan cerca de $q^* = 4$ y las ganancias se estabilizan alrededor de 32.

Sin embargo, la velocidad de convergencia no es igual, FP converge de forma limpia luego de algunas iteraciones iniciales, mientras que RM necesita aproximadamente 300 iteraciones para estabilizarse alrededor del equilibrio de Nash. Esto ocurre porque RM ajusta su política a partir de arrepentimientos acumulados, al inicio, pequeñas diferencias entre acciones pueden generar oscilaciones, y recién después de acumular suficiente evidencia las probabilidades se concentran en cantidades cercanas a $q^* = 4$.




Figura 122: Experimento mixto entre Regret Matching y Fictitious Play en Cournot.

En el experimento mixto entre RM y FP, ambos agentes convergen rápidamente hacia la cantidad de equilibrio $q^* = 4$. De las gráficas se puede apreciar que FP se estabiliza de forma más directa, mientras que RM presenta algunas oscilaciones iniciales antes de concentrar su política cerca del equilibrio. Aun así, ambos terminan produciendo cantidades cercanas al equilibrio de Nash. También se observa que el uso combinado de RM y FP no impide la convergencia. Esto ocurre porque ambos algoritmos actualizan sus decisiones a partir de información histórica del juego: FP estima la estrategia promedio del rival y responde a ella, mientras que RM ajusta sus probabilidades según el arrepentimiento acumulado por no haber elegido otras cantidades. Al interactuar entre sí, estas reglas de actualización llevan a que las cantidades se corrijan progresivamente hasta ubicarse cerca de $q^* = 4$.

Cournot con dos jugadores: algoritmos de aprendizaje por refuerzo multiagente (IQL y JAL-AM)




Figura 123: Convergencia de IQL en Cournot con 2 jugadores.




Figura 124: Convergencia de JAL-AM en Cournot con 2 jugadores.

Como era esperable, IQL y JAL-AM no logran converger de forma estable al equilibrio de Nash. Esto se debe a su condición de algoritmos de aprendizaje por refuerzo multiagente, cada firma aprende mientras la otra también cambia su política, por lo que el entorno visto por cada agente no es estacionario. JAL-AM reduce parcialmente este problema al modelar las acciones del oponente, pero las cantidades elegidas siguen oscilando y no se estabilizan de manera robusta en $q^* = 4$.

Tres jugadores




Figura 125: Convergencia de Regret Matching en Cournot con 3 jugadores.




Figura 126: Convergencia de Fictitious Play en Cournot con 3 jugadores.




Figura 127: Distribuciones de estrategia de RM y FP en Cournot con 3 jugadores.

Al pasar de dos a tres firmas, el equilibrio por firma baja de $q = 4$ a $q = 3$, ya que al haber más competidores, cada firma produce menos individualmente, pero la producción total del mercado aumenta. En esta configuración, FP converge de manera muy clara hacia $q = 3$, mientras que RM también se mantiene cerca del equilibrio, aunque con más fluctuaciones en las cantidades y ganancias.

La distribución de estrategias confirma este comportamiento. En ambos algoritmos, la mayor parte de la probabilidad se concentra alrededor de la cantidad de equilibrio $q^* = 3$, lo que indica que las firmas aprendieron a producir cerca del valor esperado por el modelo de Cournot. Sin embargo, FP presenta una distribución más dispersa, con pequeñas probabilidades asignadas a cantidades alejadas del equilibrio. RM, en cambio, concentra con mayor fuerza la probabilidad cerca de $q = 3$, aunque todavía aparecen diferencias entre firmas, especialmente en una de ellas, que asigna parte de su probabilidad a cantidades algo mayores. Esto muestra que ambos algoritmos capturan el equilibrio, pero no con el mismo grado de concentración estratégica.

Experimento Mixto: 2 FP + 1 RM




Figura 128: Experimento mixto con dos firmas FP y una firma RM en Cournot con 3 jugadores.

También se evaluó una configuración mixta con dos firmas entrenadas mediante FP y una firma entrenada mediante RM. A diferencia de los experimentos homogéneos, donde FP y RM logran acercarse al equilibrio de Cournot, en este caso la interacción entre reglas de actualización distintas genera una dinámica más inestable. Las firmas no logran coordinarse de forma robusta alrededor de $q^* = 3$ y las cantidades elegidas permanecen más dispersas durante el entrenamiento.

Este resultado sugiere que, al pasar a tres jugadores, mezclar algoritmos puede amplificar la no estacionariedad del entorno. Cada firma actualiza su política a partir de señales históricas diferentes, FP responde a frecuencias observadas, mientras que RM ajusta sus probabilidades según arrepentimientos acumulados. Cuando estos mecanismos conviven en un mercado con tres firmas, las mejores respuestas cambian de forma más irregular y la convergencia se vuelve menos limpia que en self-play.

Además, se probó la configuración inversa, con una firma FP y dos firmas RM. Los resultados fueron aún peores, ninguna de las firmas logró converger de manera estable al equilibrio.

Tres jugadores: mercado medio

Para evaluar si el comportamiento se mantiene al aumentar el tamaño del mercado, se probó una configuración intermedia con $a = 50$, $b = 1$, $c = 10$, tres firmas y 51 acciones posibles entre 0 y 25 unidades. En este caso, el equilibrio de Nash teórico es:

$$q^* = \frac{a - c}{(n + 1)b} = \frac{50 - 10}{4 \cdot 1} = 10$$

La cantidad total de equilibrio es $Q^* = 30$, el precio de equilibrio es $P^* = 20$ y la ganancia esperada por firma es $\pi^* = 100$.




Figura 129: Convergencia de Regret Matching en Cournot con 3 jugadores y mercado medio.




Figura 130: Convergencia de Fictitious Play en Cournot con 3 jugadores y mercado medio.




Figura 131: Distribuciones de estrategia de RM y FP en Cournot con 3 jugadores y mercado medio.

En el mercado medio, RM logra concentrar la estrategia de las tres firmas exactamente alrededor de $q^* = 10$. Esto muestra que el algoritmo sigue capturando correctamente la mejor respuesta aun cuando el espacio de acciones es más grande que en el experimento base.

FP también logra llegar al equilibrio para las tres firmas, pero necesita más iteraciones para

hacerlo, esto se debe a que que necesitaba más historial para estabilizar correctamente sus creencias sobre los rivales. Como FP responde a frecuencias acumuladas, cuando el espacio de acciones crece, las diferencias iniciales pueden tardar más en corregirse. Con suficientes iteraciones, la estimación histórica se ajusta y la mejor respuesta vuelve a coincidir con el equilibrio.

La figura de distribuciones de estrategia permite ver con más detalle cómo cada algoritmo asigna probabilidad a las distintas cantidades posibles. En el caso de RM, las tres firmas muestran picos muy concentrados sobre $q = 10$, con prácticamente ninguna probabilidad asignada a otras cantidades. Esto significa que RM no solo se acerca al equilibrio en promedio, sino que prácticamente juega q^* como estrategia pura, lo cual es consistente con la naturaleza del juego.

En el caso de FP, la distribución final también queda concentrada sobre $q = 10$ para las tres firmas. La diferencia respecto a RM está en la velocidad: RM se concentra antes, mientras que FP necesita acumular más observaciones para que las frecuencias históricas de los rivales dejen de estar sesgadas por las primeras iteraciones.

Tres jugadores: mercado de tamaño grande

Luego se escaló el problema a un mercado grande con $a = 100$, $b = 1$, $c = 16$, tres firmas y 81 acciones posibles entre 0 y 40 unidades. El equilibrio de Nash teórico pasa a:

$$q^* = \frac{a - c}{(n + 1)b} = \frac{100 - 16}{4 \cdot 1} = 21$$

La cantidad total de equilibrio es $Q^* = 63$, el precio de equilibrio es $P^* = 37$ y la ganancia esperada por firma es $\pi^* = 441$.




Figura 132: Convergencia de Regret Matching en Cournot con 3 jugadores y mercado grande.




Figura 133: Convergencia de Fictitious Play en Cournot con 3 jugadores y mercado grande.




Figura 134: Distribuciones de estrategia de RM y FP en Cournot con 3 jugadores y mercado grande.

En el mercado grande se observa con más claridad el efecto de escalar el espacio de acciones. RM sigue ubicando a las firmas muy cerca del equilibrio, con las cantidades más probables quedan alrededor de 21. Las ganancias oscilan alrededor de la ganancia de Nash, pero las oscilaciones son mayores que en el mercado medio porque una desviación pequeña en cantidad tiene un impacto más grande sobre la producción total y sobre el precio.

FP también se mueve hacia la zona del equilibrio, pero su convergencia es menos limpia. Al haber 91 acciones disponibles, necesita más observaciones para estimar correctamente la distribución histórica de los rivales. Además, en Cournot las firmas están acopladas por la producción total, entonces, si una firma produce un poco más, baja el precio para todas; si produce un poco menos, puede mejorar la ganancia de las otras. Por eso, cerca del equilibrio aparecen ajustes constantes entre cantidades vecinas. Lo importante es que las políticas no se dispersan por todo el espacio de acciones, sino que se concentran alrededor de la cantidad teórica, indicando que ambos algoritmos escalan razonablemente al mercado grande.

Observaciones

Los resultados de Cournot muestran que los algoritmos basados en teoría de juegos, especialmente FP y RM, capturan bien la estructura estratégica del problema. En este ambiente, aprender una buena política no consiste solamente en obtener una ganancia alta en una iteración puntual, sino en estabilizar una cantidad que siga siendo razonable cuando las demás firmas también ajustan su producción.

Al aumentar el tamaño del mercado, ambos algoritmos mantienen el comportamiento esperado, aunque la convergencia se vuelve más exigente. En el mercado medio las estrategias se concentran alrededor de $q^* = 10$, mientras que en el mercado grande se ubican cerca de $q^* = 21$. En este último caso aparecen más oscilaciones, ya que el espacio de acciones es mayor y pequeñas diferencias de cantidad afectan la producción total, el precio y las ganancias de todas las firmas.

RM tiende a concentrar más la probabilidad alrededor del equilibrio de Nash, mientras que FP también lo aproxima correctamente pero con distribuciones finales más dispersas. Además, se intentó evaluar mercados más grandes y escenarios con mayor cantidad de firmas, pero el costo computacional no permitió que todos los algoritmos finalizaran en un tiempo razonable. Esta limitación fue especialmente notoria en Fictitious Play, mientras que Regret Matching resultó considerablemente más rápido, lo que sugiere que FP presenta mayores dificultades para escalar a problemas de gran tamaño.

Los resultados de IQL y JAL-AM se interpretan como referencia secundaria, los mismos muestran que maximizar la recompensa observada no alcanza para garantizar estabilidad estratégica. En Cournot, lo central es verificar si la política aprendida permanece cerca de un equilibrio frente a desviaciones unilaterales.

Otra observación interesante es que en general los agentes no han capturado equilibrios no puros, aunque esta situación si nos ocurrió una vez en BoS, sin embargo, tras re ejecutar el notebook en reiteradas ocasiones, no pudimos reproducir el escenario.

5. Conclusion

En juegos de sistemas multiagentes, el desempeño de los agentes depende fuertemente de la estructura del juego, de si es competitivo, cooperativo o mixto, y de si el entorno se mantiene estacionario mientras los agentes aprenden. Fictitious Play suele ser útil cuando el agente puede aproximar el comportamiento promedio del oponente y responder a sus frecuencias históricas, aunque puede oscilar si el rival cambia constantemente. Regret Matching tiende a ser robusto en juegos repetidos, porque ajusta su política reduciendo el arrepentimiento acumulado y puede aproximar equilibrios en términos de comportamiento promedio. IQL es simple y práctico, pero suele ser más inestable en escenarios multiagente, ya que cada agente aprende como si los demás fueran parte del entorno, ignorando que también están aprendiendo. JAL-AM, al modelar acciones conjuntas y estimar el comportamiento promedio del rival, suele capturar mejor la dependencia estratégica entre agentes que IQL, aunque también puede sufrir oscilaciones si todos los agentes adaptan sus políticas simultáneamente.

En el caso de juegos matriciales como Matching Pennies y Rock-Paper-Scissors, el problema puede analizarse como una interacción estratégica repetida, donde conceptos como mejor respuesta, arrepentimiento y equilibrio de Nash permiten evaluar no solamente la recompensa obtenida en una corrida particular, sino la estabilidad de la política aprendida frente a desviaciones del rival. En ambientes secuenciales como Foraging o Cournot, la interacción se aproxima más a un juego estocástico: las acciones conjuntas afectan recompensas y también la evolución del estado. Por eso, aprender una buena política no consiste únicamente en maximizar recompensas inmediatas, sino en encontrar comportamientos que sean robustos respecto a las políticas de los otros agentes y al efecto que estas tienen sobre la dinámica futura del entorno.

Una conclusión importante es que MARL no puede entenderse únicamente como una extensión directa del aprendizaje por refuerzo clásico. Al combinar aprendizaje por refuerzo con teoría de juegos, aparecen dificultades que no tienen la misma fuerza en el caso de un único agente. La más clara en los experimentos realizados fue la no estacionariedad: desde la perspectiva de un agente

independiente, las transiciones y recompensas cambian porque los demás agentes también actualizan sus políticas. Esto explica las oscilaciones observadas en IQL y, en menor medida, en JAL-AM. A su vez, los experimentos cooperativos muestran la importancia de distinguir entre recompensa individual y desempeño colectivo: en tareas de coordinación, la política aprendida debe resolver problemas de asignación de crédito, observabilidad parcial y acción conjunta. En conjunto, los resultados confirman que la elección del algoritmo debe depender del modelo de interacción: enfoques basados en teoría de juegos son especialmente adecuados cuando el equilibrio estratégico es el objeto central de análisis, mientras que enfoques de aprendizaje por refuerzo multiagente resultan más generales pero requieren mecanismos adicionales para manejar la no estacionariedad, la coordinación y el modelado de otros agentes.

Referencias

- [1] Albrecht, S. V., Christianos, F., and Schäfer, L. (2024). *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches*.
- [2] Mussio, M. and Campiglia, N. (2026). simultaneous-games. <https://github.com/mmussio85/simultaneous-games>. Repositorio de código.